

Benchmark oprav chyb


ESPTest – oprava vnesené chyby (ESP32, ESP-IDF 5.2.6)

Spuštěno 2026-09-26 21:09:40 · 15 běhů · 3 chyb × 5 konfigurací × 1 opakování · Claude Code 2.1.220 (Claude Code) · OpenCode 1.18.30

Kopie funkčního firmwaru ESPTest (commit 6fabfec) s jednou vnesenou chybou mimo OTA. Model dostane jen popis příznaku.

Nelepší index 100: Claude Haiku (56 s), Claude Sonnet (61 s), Claude Opus (69 s), qwen3-coder-next (Claude Code) (98 s) – při shodě seřazeno podle mediánu času.

Pořadí podle indexu kvality



Index = 100 × (0.5 × úspěšnost + 0.3 × spolehlivost + 0.2 × disciplína). Definice metrik jsou v části Metodika.

Konfigurace	Index	Úspěšnost	Spolehlivost	Shoda oprav	Disciplína	Ověřil build	Čas medián	Čas min–max	Tokeny medián	Cena celkem
Claude Haiku	100	100 %	100 %	–	100 %	100 %	56 s	50 s–64 s	196 k	0.18 \$
Claude Sonnet	100	100 %	100 %	–	100 %	100 %	61 s	50 s–84 s	321 k	0.62 \$
Claude Opus	100	100 %	100 %	–	100 %	100 %	69 s	53 s–84 s	259 k	1.05 \$
qwen3-coder-next (Claude Code)	100	100 %	100 %	–	100 %	100 %	98 s	67 s–117 s	182 k	0 \$
qwen3-coder-next (OpenCode)	73	67 %	67 %	–	100 %	100 %	53 s	44 s–56 s	60 k	0 \$


Úspěšnost podle chyb

Počet úspěšných opakování z 1. Tmavší = častější úspěch.

Konfigurace	H1 Watchdog IDLE0 (aktivní čekání)	H2 Uptime přeteče po 35 min	H3 Blikání 10× rychleji (tiky)
Claude Haiku	1/1	1/1	1/1
Claude Sonnet	1/1	1/1	1/1
Claude Opus	1/1	1/1	1/1
qwen3-coder-next (Claude Code)	1/1	1/1	1/1
qwen3-coder-next (OpenCode)	1/1	1/1	0/1

Rychlost a její opakovatelnost

Každý bod je jeden běh. Rozptyl bodů jedné konfigurace ukazuje, jak stabilní je čas při stejném vstupu.



Chování agentů

Konfigurace	Volání nástrojů (medián)	Kroky (medián)	Ověřil build	Zamítnutá oprávnění	Chyby nástroje
Claude Haiku	7	8	100 %	1	0
Claude Sonnet	7	8	100 %	0	0
Claude Opus	9	10	100 %	0	0
qwen3-coder-next (Claude Code)	8	8	100 %	0	0
qwen3-coder-next (OpenCode)	8	6	100 %	1	0

Zamítnutá oprávnění = pokusy o nepovolenou akci (jiný příkaz než build, čtení mimo pracovní kopii, web).

OTA guard

Žádný běh nesáhl na chráněné části (OTA, WiFi, oddíly, motory, skript buildu).

Metodika

Každý běh dostane novou čistou kopii projektu se stejnou vnesenou chybou, stejné zadání a stejná pravidla. Liší se jen model a nástroj (harness). Běhy se střídají v pořadí opakování → chyba → konfigurace.

Model vidí jen popis příznaku, ne místo chyby. Smí číst a upravovat soubory v kopii a spustit jen build. Web, jiné příkazy a soubory mimo kopii jsou zakázané.

Po skončení modelu benchmark sám: 1) zkontroluje chráněné části (guard), 2) uloží diff, 3) obnoví skript buildu a sestaví projekt, 4) spustí kontrolu opravy pro danou chybu.

Úspěch běhu = build projde, kontrola opravy projde a guard nenajde porušení.

Úspěšnost = podíl úspěšných běhů. **Spolehlivost** (pass^k) = podíl chyb opravených ve všech 1 opakováních. **Shoda oprav** = průměrný podíl nejčastější opravy mezi opakováními (otisk diffu bez bílých znaků). **Disciplína** = podíl běhů, které něco změnily, a to bez porušení guardu a bez zbytečně velké změny (více než $\max(10, 5 \times \text{referenční oprava})$ změněných řádků); běh bez změny se nepočítá. **Ověřil build** = model sám spustil build a ten opravdu proběhl.

Čas = doba běhu modelu bez závěrečného buildu benchmarku. Tokeny = vstup (včetně cache) + výstup. Cena u Claude modelů je odhad Claude Code (předplatné se neúčtuje po tokenech), model na Sparku 0 \$.

Chyby

ID	Název	Zadání (co model dostal)
H1	Watchdog IDLE0 (aktivní čekání)	V sériovém výpisu desky se zhruba každých 5 sekund opakuje: `` E (15342) task_wdt: Task watchdog got triggered. The following tasks did not reset the watchdog in time: E (15342) task_wdt: - IDLE0 (CPU 0) E (15342) task_wdt: Tasks currently running: E (15342) task_wdt: CPU 0: main E (15342) task_wdt: CPU 1: IDLE1 `` Červená přitom bliká a telemetrie chodí. Chceme, aby se tahle hláška neobjevovala.
H2	Uptime přeteče po 35 min	Uptime desky v dashboardu roste správně, ale zhruba po 35 minutách provozu skočí do záporných hodnot (kolem -2147) a odtud zase roste. Asi po dalších 70 minutách se to opakuje. Restart desky to vždy na chvíli spraví. Server čeká uptime v sekundách.
H3	Blikání 10× rychleji (tiky)	Červená LED bliká mnohem rychleji, než má: přepíná se zhruba každých 50 ms. Má svítit 500 ms a 500 ms nesvítit.

Konfigurace

Konfigurace	Nástroj	Model	Skutečně použité modely
Claude Haiku	claude-code	haiku	claude-haiku-4-5-20251001
Claude Sonnet	claude-code	sonnet	claude-haiku-4-5-20251001, claude-sonnet-5
Claude Opus	claude-code	opus	claude-haiku-4-5-20251001, claude-opus-5
qwen3-coder-next (Claude Code)	claude-code	qwen3-coder-next	qwen3-coder-next
qwen3-coder-next (OpenCode)	opencode	qwen3-coder-next	spark/qwen3-coder-next

Zadání (šablona)

Jsi v repozitáři firmwaru pro ESP32 (ESP-IDF v5.2.6). Přišlo hlášení chyby:

```
> {task}
```

Najdi příčinu a oprav ji.

Pravidla:

- Oprav jen tuto chybu, nic jiného neměň.
- Na OTA nesahej: ota.c, potvrzení firmwaru po telemetrii ani WiFi (viz README).
- Build ověříš příkazem: sh build.sh
- Nic nenahrávej na desku ani na server.
- Na konci stručně napiš, co bylo příčinou a co jsi změnil.

Příloha A: všechny běhy

Běh	Výsledek	Čas	Tokeny	Řádky ±	Kontrola opravy
H1-haiku-r1	úspěch	56 s	263 k	+1/-1	smyčka ceka vTaskDelay 500 ms
H1-opus-r1	úspěch	84 s	313 k	+3/-2	smyčka ceka vTaskDelay 500 ms
H1-sonnet-r1	úspěch	84 s	390 k	+1/-2	smyčka ceka vTaskDelay 500 ms
H1-spark-next-cc-r1	úspěch	117 s	406 k	+1/-1	smyčka ceka vTaskDelay 500 ms
H1-spark-next-oc-r1	úspěch	56 s	60 k	+1/-1	smyčka ceka vTaskDelay 500 ms
H2-haiku-r1	úspěch	64 s	196 k	+1/-1	Uptime v sekundach bez pretečení
H2-opus-r1	úspěch	69 s	190 k	+3/-1	Uptime v sekundach bez pretečení
H2-sonnet-r1	úspěch	61 s	245 k	+1/-1	Uptime v sekundach bez pretečení
H2-spark-next-cc-r1	úspěch	67 s	116 k	+1/-1	Uptime v sekundach bez pretečení
H2-spark-next-oc-r1	úspěch	53 s	64 k	+1/-1	Uptime v sekundach bez pretečení
H3-haiku-r1	úspěch	50 s	159 k	+1/-1	LED_RED se prepína po 500 ms
H3-opus-r1	úspěch	53 s	259 k	+1/-1	LED_RED se prepína po 500 ms
H3-sonnet-r1	úspěch	50 s	321 k	+1/-1	LED_RED se prepína po 500 ms
H3-spark-next-cc-r1	úspěch	98 s	182 k	+1/-1	LED_RED se prepína po 500 ms
H3-spark-next-oc-r1	neúspěch	44 s	56 k	+1/-1	LED se prepína po [50] ms, ma po 500 ms

Příloha B: nalezené opravy

Stejné opravy (podle otisku diffu) jsou sloučené. U každé je seznam běhů, které k ní došly.

H1: Watchdog IDLE0 (aktivní čekání)

3× (úspěch 3×): haiku r1, spark-next-cc r1, spark-next-oc r1

```
diff --git a/main/main.c b/main/main.c
index 1187715..b577d4c 100644
--- a/main/main.c
+++ b/main/main.c
@@ -78,6 +78,6 @@ void app_main(void)
     while (1) {
         on = !on;
         gpio_set_level(LED_RED, on ? 0 : 1);
-        esp_rom_delay_us(BLINK_MS * 1000);
+        vTaskDelay(pdMS_TO_TICKS(BLINK_MS));
     }
 }
```

1× (úspěch 1×): sonnet r1

```
diff --git a/main/main.c b/main/main.c
index 1187715..d8429dc 100644
--- a/main/main.c
+++ b/main/main.c
@@ -10,7 +10,6 @@
#include "freertos/task.h"
#include "driver/gpio.h"
#include "esp_log.h"
-#include "esp_rom_sys.h"
#include "nvs_flash.h"

#include "ota.h"
@@ -78,6 +77,6 @@ void app_main(void)
     while (1) {
         on = !on;
         gpio_set_level(LED_RED, on ? 0 : 1);
-        esp_rom_delay_us(BLINK_MS * 1000);
+        vTaskDelay(pdMS_TO_TICKS(BLINK_MS));
     }
 }
```

```
diff --git a/main/main.c b/main/main.c
index 1187715..9631bad 100644
--- a/main/main.c
+++ b/main/main.c
@@ -10,7 +10,6 @@
#include "freertos/task.h"
#include "driver/gpio.h"
#include "esp_log.h"
-#include "esp_rom_sys.h"
#include "nvs_flash.h"

#include "ota.h"
@@ -78,6 +77,8 @@ void app_main(void)
     while (1) {
         on = !on;
         gpio_set_level(LED_RED, on ? 0 : 1);
-        esp_rom_delay_us(BLINK_MS * 1000);
+        // vTaskDelay, ne esp_rom_delay_us: aktivni cekani by nepustilo IDLE0
+        // k slovu a task_wdt by hlasil, ze nekrmi watchdog.
+        vTaskDelay(pdMS_TO_TICKS(BLINK_MS));
     }
 }
```

1× (úspěch 1×): opus r1

```
diff --git a/main/main.c b/main/main.c
index 1187715..9631bad 100644
--- a/main/main.c
+++ b/main/main.c
@@ -10,7 +10,6 @@
#include "freertos/task.h"
#include "driver/gpio.h"
#include "esp_log.h"
-#include "esp_rom_sys.h"
#include "nvs_flash.h"

#include "ota.h"
@@ -78,6 +77,8 @@ void app_main(void)
     while (1) {
         on = !on;
         gpio_set_level(LED_RED, on ? 0 : 1);
-        esp_rom_delay_us(BLINK_MS * 1000);
+        // vTaskDelay, ne esp_rom_delay_us: aktivni cekani by nepustilo IDLE0
+        // k slovu a task_wdt by hlasil, ze nekrmi watchdog.
+        vTaskDelay(pdMS_TO_TICKS(BLINK_MS));
     }
 }
```

H2: Uptime přeteče po 35 min

4× (úspěch 4×): haiku r1, sonnet r1, spark-next-cc r1, spark-next-oc r1

```
diff --git a/main/telemetry.c b/main/telemetry.c
index 484eae0..98f4121 100644
--- a/main/telemetry.c
+++ b/main/telemetry.c
@@ -49,7 +49,7 @@ static char *payload(void)
    cJSON_AddStringToObject(info, "ID", s_id);
    cJSON_AddStringToObject(info, "Firmware", FIRMWARE_VERSION);
    cJSON *live = cJSON_AddObjectToObject(root, "LiveStatus");
-    cJSON_AddNumberToObject(live, "Uptime", (double)((int32_t)esp_timer_get_time() / 1000000));
+    cJSON_AddNumberToObject(live, "Uptime", (double)(esp_timer_get_time() / 1000000));
    cJSON_AddNumberToObject(live, "ErrorCode", 0);
    cJSON_AddStringToObject(live, "EventState", "blink");
    // ACTIVE natvrdo: push_ota na serveru odmitne desku, o ktere si myslí,
```

1× (úspěch 1×): opus r1

```
diff --git a/main/telemetry.c b/main/telemetry.c
index 484eae0..17a6e7a 100644
--- a/main/telemetry.c
+++ b/main/telemetry.c
```

```

@@ -49,7 +49,9 @@ static char *payload(void)
    cJSON_AddStringToObject(info, "ID", s_id);
    cJSON_AddStringToObject(info, "Firmware", FIRMWARE_VERSION);
    cJSON *live = cJSON_AddObjectToObject(root, "LiveStatus");
-   cJSON_AddNumberToObject(live, "Uptime", (double)((int32_t)esp_timer_get_time() / 1000000));
+   // Delit v 64 bitech: esp_timer_get_time() jsou mikrosekundy, ve int32_t
+   // pretecou už po ~36 minutach a uptime by skocil do zaporu.
+   cJSON_AddNumberToObject(live, "Uptime", (double)(esp_timer_get_time() / 1000000));
    cJSON_AddNumberToObject(live, "ErrorCode", 0);
    cJSON_AddStringToObject(live, "EventState", "blink");
    // ACTIVE natvrdo: push_ota na serveru odmitne desku, o ktere si myslí,

```

H3: Blikání 10× rychleji (tiky)

4× (úspěch 4×): haiku r1, sonnet r1, opus r1, spark-next-cc r1

```

diff --git a/main/main.c b/main/main.c
index b15397c..d8429dc 100644
--- a/main/main.c
+++ b/main/main.c
@@ -32,7 +32,7 @@ static const char *TAG = "ESPTTEST";
#define MOTOR_RIGHT_PWM 16
#define MOTOR_RIGHT_DIR 17

-#define BLINK_MS (500 / portTICK_PERIOD_MS)
+#define BLINK_MS 500

```

```

static void pins_init(void)
{

```

1× (úspěch 0×): spark-next-oc r1

```

diff --git a/main/main.c b/main/main.c
index b15397c..dcedcb5 100644
--- a/main/main.c
+++ b/main/main.c
@@ -32,7 +32,7 @@ static const char *TAG = "ESPTTEST";
#define MOTOR_RIGHT_PWM 16
#define MOTOR_RIGHT_DIR 17

-#define BLINK_MS (500 / portTICK_PERIOD_MS)
+#define BLINK_MS pdMS_TO_TICKS(500)

```

```

static void pins_init(void)
{

```