

Benchmark oprav chyb


ESPTTest – oprava vnesené chyby (ESP32, ESP-IDF 5.2.6)

Spuštěno 2026-09-26 19:39:24 · 40 běhů · 4 chyb × 5 konfigurací × 2 opakování · Claude Code 2.1.220 (Claude Code) · OpenCode 1.18.30

Kopie funkčního firmwaru ESPTTest (commit 6fabfec) s jednou vnesenou chybou mimo OTA. Model dostane jen popis příznaku. Plánována 3 opakování, na žádost uživatele zkráceno na 2 (40 běhů); spolehlivost je proto pass^2 a není přímo srovnatelná s během z 25. 9. (pass^3).

Nejlepší index 100: Claude Haiku (48 s), Claude Sonnet (58 s), Claude Opus (67 s) – při shodě seřazeno podle mediánu času.

Pořadí podle indexu kvality



Index = 100 × (0.5 × úspěšnost + 0.3 × spolehlivost + 0.2 × disciplína). Definice metrik jsou v části Metodika.

Konfigurace	Index	Úspěšnost	Spolehlivost	Shoda oprav	Disciplína	Ověřil build	Čas medián	Čas min–max	Tokeny medián	Cena celkem
Claude Haiku	100	100 %	100 %	88 %	100 %	100 %	48 s	40 s–60 s	162 k	0.47 \$
Claude Sonnet	100	100 %	100 %	100 %	100 %	100 %	58 s	43 s–2.4 min	244 k	1.57 \$
Claude Opus	100	100 %	100 %	75 %	100 %	100 %	67 s	43 s–113 s	241 k	2.76 \$
qwen3-coder-next (OpenCode)	84	88 %	75 %	75 %	88 %	100 %	55 s	39 s–4.1 min	64 k	0 \$
qwen3-coder-next (Claude Code)	84	88 %	75 %	88 %	88 %	88 %	59 s	30 s–107 s	149 k	0 \$


Úspěšnost podle chyb

Počet úspěšných opakování z 2. Tmavší = častější úspěch.

Konfigurace	B1 Bliká modrá místo červené	B2 Červená trvale svítí, nebliká	B3 Uptime 1000× větší	B4 Únik paměti v telemetrii
Claude Haiku	2/2	2/2	2/2	2/2
Claude Sonnet	2/2	2/2	2/2	2/2
Claude Opus	2/2	2/2	2/2	2/2
qwen3-coder-next (Claude Code)	2/2	2/2	2/2	1/2
qwen3-coder-next (OpenCode)	2/2	2/2	2/2	1/2

Rychlost a její opakovatelnost

Každý bod je jeden běh. Rozptyl bodů jedné konfigurace ukazuje, jak stabilní je čas při stejném vstupu.



Chování agentů

Konfigurace	Volání nástrojů (medián)	Kroky (medián)	Ověřil build	Zamítnutá oprávnění	Chyby nástroje
Claude Haiku	7	8	100 %	0	0
Claude Sonnet	5	6	100 %	1	0
Claude Opus	8	9	100 %	0	0
qwen3-coder-next (Claude Code)	8	8	88 %	5	0
qwen3-coder-next (OpenCode)	10	6	100 %	4	0

Zamítnutá oprávnění = pokusy o nepovolenou akci (jiný příkaz než build, čtení mimo pracovní kopii, web).

OTA guard

Běh	Porušení
B4-spark-next-oc-r2	zmeneny nebo chybejici chranyeny soubor main/ota.c

Metodika

Každý běh dostane novou čistou kopii projektu se stejnou vnesenou chybou, stejné zadání a stejná pravidla. Liší se jen model a nástroj (harness). Běhy se střídají v pořadí opakování → chyba → konfigurace.

Model vidí jen popis příznaku, ne místo chyby. Smí číst a upravovat soubory v kopii a spustit jen build. Web, jiné příkazy a soubory mimo kopii jsou zakázané.

Po skončení modelu benchmark sám: 1) zkontroluje chráněné části (guard), 2) uloží diff, 3) obnoví skript buildu a sestaví projekt, 4) spustí kontrolu opravy pro danou chybu.

Úspěch běhu = build projde, kontrola opravy projde a guard nenajde porušení.

Úspěšnost = podíl úspěšných běhů. **Spolehlivost** (pass^k) = podíl chyb opravených ve všech 2 opakováních. **Shoda oprav** = průměrný podíl nejčastější opravy mezi opakováními (otisk diffu bez bílých znaků). **Disciplína** = podíl běhů, které něco změnily, a to bez porušení guardu a bez zbytečně velké změny (více než max(10, 5 × referenční oprava) změněných řádků); běh bez změny se nepočítá. **Ověřil build** = model sám spustil build a ten opravdu proběhl.

Čas = doba běhu modelu bez závěrečného buildu benchmarku. Tokeny = vstup (včetně cache) + výstup. Cena u Claude modelů je odhad Claude Code (předplatné se neúčtuje po tokenech), model na Sparku 0 \$.

Chyby

ID	Název	Zadání (co model dostal)
B1	Bliká modrá místo červené	Po nahrání tohoto firmwaru na desku bliká modrá LED místo červené. Červená nesvítí vůbec. Podle zadání projektu má blikat červená.
B2	Červená trvale svítí, neblinká	Červená LED po startu desky trvale svítí a neblinká. Má blikat: 500 ms svítí, 500 ms nesvítí.
B3	Uptime 1000× větší	Dashboard ukazuje u desky uptime zhruba 1000× větší, než odpovídá skutečnosti: po minutě provozu hlásí kolem 60 000. Server čeká uptime v sekundách.
B4	Únik paměti v telemetrii	Deska po několika hodinách provozu spadne a restartuje se. Při sledování volné paměti (esp_get_free_heap_size) je vidět, že volný heap klesá o několik set bajtů zhruba každých 5 sekund.

Konfigurace

Konfigurace	Nástroj	Model	Skutečně použité modely
Claude Haiku	claude-code	haiku	claude-haiku-4-5-20251001
Claude Sonnet	claude-code	sonnet	claude-haiku-4-5-20251001, claude-sonnet-5
Claude Opus	claude-code	opus	claude-haiku-4-5-20251001, claude-opus-5
qwen3-coder-next (Claude Code)	claude-code	qwen3-coder-next	qwen3-coder-next
qwen3-coder-next (OpenCode)	opencode	qwen3-coder-next	spark/qwen3-coder-next

Zadání (šablona)

Jsi v repozitáři firmwaru pro ESP32 (ESP-IDF v5.2.6). Přišlo hlášení chyby:

> {task}

Najdi příčinu a oprav ji.

Pravidla:

- Oprav jen tuto chybu, nic jiného neměň.
- Na OTA nesahej: ota.c, potvrzení firmwaru po telemetrii ani WiFi (viz README).
- Build ověříš příkazem: sh build.sh
- Nic nenahrávej na desku ani na server.
- Na konci stručně napiš, co bylo příčinou a co jsi změnil.

Příloha A: všechny běhy

Běh	Výsledek	Čas	Tokeny	Řádky ±	Kontrola opravy
B1-haiku-r1	úspěch	59 s	192 k	+1/-1	blika cervena (27)
B1-haiku-r2	úspěch	44 s	159 k	+1/-1	blika cervena (27)
B1-opus-r1	úspěch	61 s	191 k	+1/-1	blika cervena (27)
B1-opus-r2	úspěch	49 s	258 k	+1/-1	blika cervena (27)
B1-sonnet-r1	úspěch	48 s	246 k	+1/-1	blika cervena (27)
B1-sonnet-r2	úspěch	62 s	326 k	+1/-1	blika cervena (27)
B1-spark-next-cc-r1	úspěch	65 s	182 k	+1/-1	blika cervena (27)
B1-spark-next-cc-r2	úspěch	59 s	160 k	+1/-1	blika cervena (27)
B1-spark-next-oc-r1	úspěch	48 s	57 k	+1/-1	blika cervena (27)
B1-spark-next-oc-r2	úspěch	39 s	46 k	+1/-1	blika cervena (27)
B2-haiku-r1	úspěch	44 s	162 k	+2/-2	smycka neguje 'on' a podle ni nastavuje LED_RED
B2-haiku-r2	úspěch	49 s	157 k	+1/-1	smycka neguje 'on' a podle ni nastavuje LED_RED
B2-opus-r1	úspěch	66 s	258 k	+1/-1	smycka neguje 'on' a podle ni nastavuje LED_RED
B2-opus-r2	úspěch	43 s	215 k	+1/-1	smycka neguje 'on' a podle ni nastavuje LED_RED
B2-sonnet-r1	úspěch	45 s	281 k	+1/-1	smycka neguje 'on' a podle ni nastavuje LED_RED
B2-sonnet-r2	úspěch	2.4 min	242 k	+1/-1	smycka neguje 'on' a podle ni nastavuje LED_RED
B2-spark-next-cc-r1	úspěch	56 s	111 k	+1/-1	smycka neguje 'on' a podle ni nastavuje LED_RED
B2-spark-next-cc-r2	úspěch	52 s	115 k	+1/-1	smycka neguje 'on' a podle ni nastavuje LED_RED
B2-spark-next-oc-r1	úspěch	62 s	81 k	+1/-1	smycka neguje 'on' a podle ni nastavuje LED_RED
B2-spark-next-oc-r2	úspěch	65 s	71 k	+3/-3	smycka strida LED_RED 0/1 se dvema zpozdenimi
B3-haiku-r1	úspěch	48 s	159 k	+1/-1	Uptime v sekundach
B3-haiku-r2	úspěch	40 s	162 k	+1/-1	Uptime v sekundach
B3-opus-r1	úspěch	79 s	188 k	+1/-1	Uptime v sekundach
B3-opus-r2	úspěch	113 s	224 k	+2/-1	Uptime v sekundach
B3-sonnet-r1	úspěch	43 s	199 k	+1/-1	Uptime v sekundach
B3-sonnet-r2	úspěch	63 s	243 k	+1/-1	Uptime v sekundach
B3-spark-next-cc-r1	úspěch	62 s	139 k	+1/-1	Uptime v sekundach
B3-spark-next-cc-r2	úspěch	60 s	160 k	+1/-1	Uptime v sekundach
B3-spark-next-oc-r1	úspěch	43 s	57 k	+1/-1	Uptime v sekundach
B3-spark-next-oc-r2	úspěch	42 s	48 k	+1/-1	Uptime v sekundach
B4-haiku-r1	úspěch	60 s	176 k	+1/-0	strom JSONu se uvolni
B4-haiku-r2	úspěch	55 s	227 k	+1/-0	strom JSONu se uvolni
B4-opus-r1	úspěch	69 s	306 k	+1/-0	strom JSONu se uvolni
B4-opus-r2	úspěch	75 s	278 k	+3/-0	strom JSONu se uvolni
B4-sonnet-r1	úspěch	67 s	290 k	+1/-0	strom JSONu se uvolni
B4-sonnet-r2	úspěch	55 s	210 k	+1/-0	strom JSONu se uvolni
B4-spark-next-cc-r1	úspěch	107 s	205 k	+1/-0	strom JSONu se uvolni
B4-spark-next-cc-r2	neúspěch	30 s	89 k	+0/-0	strom 'root' se po vytisteni neuvolni (unik pameti)
B4-spark-next-oc-r1	úspěch	2.4 min	228 k	+1/-0	strom JSONu se uvolni
B4-spark-next-oc-r2	neúspěch (guard)	4.1 min	96 k	+1/-1	strom 'root' se po vytisteni neuvolni (unik pameti)

Příloha B: nalezené opravy

Stejné opravy (podle otisku diffu) jsou sloučené. U každé je seznam běhů, které k ní došly.

B1: Bliká modrá místo červené

10× (úspěch 10×): haiku r1, sonnet r1, opus r1, spark-next-cc r1, spark-next-oc r1, haiku r2, sonnet r2, opus r2, spark-next-cc r2, spark-next-oc r2

```
diff --git a/main/main.c b/main/main.c
index c8cd1b9..d8429dc 100644
--- a/main/main.c
+++ b/main/main.c
@@ -20,7 +20,7 @@
 static const char *TAG = "ESPTEST";

// RGB dioda robota, aktivni v LOW (0 = sviti). Viz Zobo main/led.c.
#define LED_RED 12
+define LED_RED 27
#define LED_GREEN 14
#define LED_BLUE 12
#define LED_MAIN 5
```

B2: Červená trvale svítí, neblinká

8× (úspěch 8×): sonnet r1, opus r1, spark-next-cc r1, spark-next-oc r1, haiku r2, sonnet r2, opus r2, spark-next-cc r2

```
diff --git a/main/main.c b/main/main.c
index 0f0f2b5..d8429dc 100644
--- a/main/main.c
+++ b/main/main.c
@@ -75,7 +75,7 @@ void app_main(void)

    bool on = false;
    while (1) {
-       on = true;
+       on = !on;
        gpio_set_level(LED_RED, on ? 0 : 1);
        vTaskDelay(pdMS_TO_TICKS(BLINK_MS));
    }
```

1× (úspěch 1×): haiku r1

```
diff --git a/main/main.c b/main/main.c
index 0f0f2b5..29a7254 100644
--- a/main/main.c
+++ b/main/main.c
@@ -73,10 +73,10 @@ void app_main(void)
    wifi_start();
    telemetry_start();

-   bool on = false;
+   bool on = true;
    while (1) {
-       on = true;
+       on = !on;
        gpio_set_level(LED_RED, on ? 0 : 1);
        vTaskDelay(pdMS_TO_TICKS(BLINK_MS));
    }
```

1× (úspěch 1×): spark-next-oc r2

```
diff --git a/main/main.c b/main/main.c
index 0f0f2b5..9cce374 100644
--- a/main/main.c
+++ b/main/main.c
@@ -73,10 +73,10 @@ void app_main(void)
    wifi_start();
    telemetry_start();

-   bool on = false;
+   while (1) {
-       on = true;
+       on = true;
        gpio_set_level(LED_RED, on ? 0 : 1);
+       gpio_set_level(LED_RED, 0);
        vTaskDelay(pdMS_TO_TICKS(BLINK_MS));
+       gpio_set_level(LED_RED, 1);
        vTaskDelay(pdMS_TO_TICKS(BLINK_MS));
    }
```

B3: Uptime 1000× větší

9× (úspěch 9×): haiku r1, sonnet r1, opus r1, spark-next-cc r1, spark-next-oc r1, haiku r2, sonnet r2, spark-next-cc r2, spark-next-oc r2

```
diff --git a/main/telemetry.c b/main/telemetry.c
index 350255d..98f4121 100644
--- a/main/telemetry.c
+++ b/main/telemetry.c
@@ -49,7 +49,7 @@ static char *payload(void)
    cJSON_AddStringToObject(info, "ID", s_id);
    cJSON_AddStringToObject(info, "Firmware", FIRMWARE_VERSION);
```

```

    cJSON *live = cJSON_AddObjectToObject(root, "LiveStatus");
-   cJSON_AddNumberToObject(live, "Uptime", (double)(esp_timer_get_time() / 1000));
+   cJSON_AddNumberToObject(live, "Uptime", (double)(esp_timer_get_time() / 1000000));
    cJSON_AddNumberToObject(live, "ErrorCode", 0);
    cJSON_AddStringToObject(live, "EventState", "blink");
    // ACTIVE natvrdo: push_ota na serveru odmitne desku, o ktorej si myslim,

1x (úspěch 1x): opus r2
diff --git a/main/telemetry.c b/main/telemetry.c
index 350255d..4b20c26 100644
--- a/main/telemetry.c
+++ b/main/telemetry.c
@@ -49,7 +49,8 @@ static char *payload(void)
    cJSON_AddStringToObject(info, "ID", s_id);
    cJSON_AddStringToObject(info, "Firmware", FIRMWARE_VERSION);
    cJSON *live = cJSON_AddObjectToObject(root, "LiveStatus");
-   cJSON_AddNumberToObject(live, "Uptime", (double)(esp_timer_get_time() / 1000));
+   // esp_timer_get_time() je v mikrosekundach, server ceka sekundy.
+   cJSON_AddNumberToObject(live, "Uptime", (double)(esp_timer_get_time() / 1000000));
    cJSON_AddNumberToObject(live, "ErrorCode", 0);
    cJSON_AddStringToObject(live, "EventState", "blink");
    // ACTIVE natvrdo: push_ota na serveru odmitne desku, o ktorej si myslim,

```

B4: Únik paměti v telemetrii

7x (úspěch 7x): haiku r1, sonnet r1, opus r1, spark-next-cc r1, spark-next-oc r1, haiku r2, sonnet r2

```

diff --git a/main/telemetry.c b/main/telemetry.c
index ae68d55..98f4121 100644
--- a/main/telemetry.c
+++ b/main/telemetry.c
@@ -58,6 +58,7 @@ static char *payload(void)
    cJSON *product = cJSON_AddObjectToObject(root, "ProductInfo");
    cJSON_AddStringToObject(product, "Název zařízení", "ESP Test");
    char *out = cJSON_PrintUnformatted(root);
+   cJSON_Delete(root);
    return out;
}

1x (úspěch 1x): opus r2
diff --git a/main/telemetry.c b/main/telemetry.c
index ae68d55..273cf5b 100644
--- a/main/telemetry.c
+++ b/main/telemetry.c
@@ -58,6 +58,9 @@ static char *payload(void)
    cJSON *product = cJSON_AddObjectToObject(root, "ProductInfo");
    cJSON_AddStringToObject(product, "Název zařízení", "ESP Test");
    char *out = cJSON_PrintUnformatted(root);
+   // Strom už je vytištěn do 'out', jinak by každá telemetrie nechala
+   // celý root v heapu. Volající uvolní 'out' přes cJSON_free().
+   cJSON_Delete(root);
    return out;
}

```

1x (úspěch 0x): spark-next-cc r2
(žádná změna)

1x (úspěch 0x): spark-next-oc r2

```

diff --git a/main/ota.c b/main/ota.c
index 4b45e58..d80ecb3 100644
--- a/main/ota.c
+++ b/main/ota.c
@@ -66,8 +66,8 @@ static void ota_task(void *arg)
    };
    esp_https_ota_config_t cfg = { .http_config = &http };

-   esp_err_t err = esp_https_ota(&cfg);
-   free(url);
+   esp_err_t err = esp_https_ota(&cfg);
+   if (err == ESP_OK) {
+       ESP_LOGI(TAG, "hotovo, restart");
+       vTaskDelay(pdMS_TO_TICKS(500));
    }

```