

Benchmark oprav chyb

ESPTTest – oprava vnesené chyby (ESP32, ESP-IDF 5.2.6)


Spuštěno 2026-09-27 15:34:44 · 8 běhů · 4 chyb × 2 konfigurací × 1 opakování · Claude Code 2.1.220 (Claude Code) · OpenCode 1.18.30

Kopie funkčního firmwaru ESPTTest (commit 6fabfec) s jednou vnesenou chybou mimo OTA. Model dostane jen popis příznaku.

Poznámka: Planovana 2 kola na high; po 1. kole (7 z 8 timeout) zastaveno a 2. kolo pusteno na medium do results/xhard-gptoss-medium-*. Reasoning: high v obou harnessech (Claude Code sam, OpenCode reasoningEffort).

Nejlepší index 35: gpt-oss-120b (OpenCode) (15.0 min).

Pořadí podle indexu kvality



Index = 100 × (0.5 × úspěšnost + 0.3 × spolehlivost + 0.2 × disciplína). Definice metrik jsou v části Metodika.

Konfigurace	Index	Úspěšnost	Spolehlivost	Shoda oprav	Disciplína	Ověřil build	Čas medián	Čas min–max	Tokeny medián	Cena celkem
gpt-oss-120b (OpenCode)	35	25 %	25 %	–	75 %	100 %	15.0 min	1.4 min–15.0 min	256 k	0 \$
gpt-oss-120b (Claude Code)	10	0 %	0 %	–	50 %	25 %	15.0 min	5.0 min–15.0 min	0 k	0 \$


Úspěšnost podle chyb

Počet úspěšných opakování z 1. Tmavší = častější úspěch.

Konfigurace	X1 Dvě chyby: LED nezhasne + únik paměti	X2 Souběh: poškozený EventState	X3 Rollback po OTA (zpoždění startu)	X4 Nová pole RSSI a MinFreeHeap
gpt-oss-120b (Claude Code)	0/1	0/1	0/1	0/1
gpt-oss-120b (OpenCode)	1/1	0/1	0/1	0/1

Rychlost a její opakovatelnost

Každý bod je jeden běh. Rozptyl bodů jedné konfigurace ukazuje, jak stabilní je čas při stejném vstupu.



Chování agentů

Konfigurace	Volání nástrojů (medián)	Kroky (medián)	Ověřil build	Zamítnutá oprávnění	Chyby nástroje
gpt-oss-120b (Claude Code)	20	0	25 %	0	4
gpt-oss-120b (OpenCode)	20	20	100 %	2	3

Zamítnutá oprávnění = pokusy o nepovolenou akci (jiný příkaz než build, čtení mimo pracovní kopii, web).

OTA guard

Žádný běh nesáhl na chráněné části (OTA, WiFi, oddíly, motory, skript buildu).

Chyby nástrojů

Běh	Chyba
X1-spark-gptoss-cc-r1	timeout
X2-spark-gptoss-cc-r1	timeout
X2-spark-gptoss-oc-r1	timeout
X3-spark-gptoss-cc-r1	timeout
X3-spark-gptoss-oc-r1	timeout
X4-spark-gptoss-cc-r1	timeout
X4-spark-gptoss-oc-r1	timeout

Typy selhání

Hlavní příčina každého neúspěchu, zařazená ručně podle přepisu agenta a diffu. Procento úspěšnosti neříká, jak model selhal, a to je pro nasazení důležitější.

Konfigurace		timeout: pomalé přemýšlení
gpt-oss-120b (Claude Code)		4
gpt-oss-120b (OpenCode)		3
Běh	Typ	Co se stalo
X1-spark-gptoss-cc-r1	timeout: pomalé přemýšlení	LED opravil správně, na únik paměti nezbyl čas. 104 tis. znaků úvah (~25k tokenů) při ~30 tok/s.
X2-spark-gptoss-cc-r1	timeout: pomalé přemýšlení	Správně poznal souběh a zaváděl mutex, čtení v payload() už chránil. Zámek zápisu a vytvoření mutexu nestihl. 112 tis. znaků úvah.
X2-spark-gptoss-oc-r1	timeout: pomalé přemýšlení	Správný směr (atomický ukazatel místo pole), úpravy zůstaly rozdělané a build neprošel.
X3-spark-gptoss-cc-r1	timeout: pomalé přemýšlení	16 kroků čtení (main.c, ota.h, README, s_pending), příčinu nenašel, do OTA nesahal. 118 tis. znaků úvah.
X3-spark-gptoss-oc-r1	timeout: pomalé přemýšlení	15 kroků, žádná změna, do OTA nesahal.
X4-spark-gptoss-cc-r1	timeout: pomalé přemýšlení	58 kroků, žádná změna v kódu.
X4-spark-gptoss-oc-r1	timeout: pomalé přemýšlení	59 kroků, stihl jen přidat #include esp_wifi.h.

Metodika

Každý běh dostane novou čistou kopii projektu se stejnou vnesenou chybou, stejné zadání a stejná pravidla. Liší se jen model a nástroj (harness). Běhy se střídají v pořadí opakování → chyba → konfigurace.

Model vidí jen popis příznaku, ne místo chyby. Smí číst a upravovat soubory v kopii a spustit jen build. Web, jiné příkazy a soubory mimo kopii jsou zakázány.

Po skončení modelu benchmark sám: 1) zkontroluje chráněné části (guard), 2) uloží diff, 3) obnoví skript buildu a sestaví projekt, 4) spustí kontrolu opravy pro danou chybu.

Úspěch běhu = build projde, kontrola opravy projde a guard nenajde porušení.

Úspěšnost = podíl úspěšných běhů. **Spolehlivost** (pass^k) = podíl chyb opravených ve všech 1 opakováních. **Shoda oprav** = průměrný podíl nejčastější opravy mezi opakováními (otisk diffu bez bílých znaků). **Disciplína** = podíl běhů, které něco změnily, a to bez porušení guardu a bez zbytečně velké změny (více než $\max(10, 5 \times \text{referenční oprava})$ změněných řádků); běh bez změny se nepočítá. **Ověřil build** = model sám spustil build a ten opravdu proběhl.

Čas = doba běhu modelu bez závěrečného buildu benchmarku. Tokeny = vstup (včetně cache) + výstup. Cena u Claude modelů je odhad Claude Code (předplatné se neúčtuje po tokenech), model na Sparku 0 \$.

Chyby

ID	Název	Zadání (co model dostal)
X1	Dvě chyby: LED nezhasne + únik paměti	Po poslední úpravě firmwaru jsou na desce dvě potíže: 1. Červená LED se po startu rozsvítí a už nezhasne. Má blikat: 500 ms svítí, 500 ms nesvítí. 2. Volný heap (<code>esp_get_free_heap_size</code>) klesá zhruba o 300 bajtů každých 5 sekund a deska se po několika hodinách sama restartuje. Oprav obojí.
X2	Souběh: poškozený EventState	Pole <code>EventState</code> v telemetrii má ukazovat, jestli červená LED právě svítí: <code>`blink_on`</code> , nebo <code>`blink_off`</code> . Většinou to sedí, ale zhruba jednou za pár dní přijde nesmyslná hodnota, třeba <code>`blink_onf`</code> nebo <code>`blink_of`</code> . Server ji odmítne a v dashboardu zůstane díra. Hlásí to víc desek a restart nepomáhá.
X3	Rollback po OTA (zpoždění startu)	Po každé OTA se deska zhruba po dvou minutách vrátí na předchozí firmware. V sériovém výpisu je: <code>W (402) OTA: zkusebni firmware z OTA, potvrdi se po první telemetrii E (120402) OTA: firmware se do 120 s nepotvrdil, vracim predchozi</code> Server i WiFi jsou v pořádku a starší verze firmwaru se po OTA potvrdily bez problémů. Po běžném restartu (bez OTA) deska funguje, jen se v dashboardu objeví až zhruba po dvou minutách. Dřív to bylo do 10 sekund.
X4	Nová pole RSSI a MinFreeHeap	Dashboard u desky ukazuje prázdné sloupce RSSI a MinFreeHeap. Server je čeká v objektu <code>LiveStatus</code> : - <code>`RSSI`</code> : síla signálu WiFi v dBm (celé číslo); - <code>`MinFreeHeap`</code> : nejnižší volný heap od startu, v bajtech. Deska je zatím vůbec neposílá. Když se RSSI zrovna nepodaří zjistit, pole RSSI neposílá vůbec (server by jinak uložil nesmysl). Ostatní pole telemetrie musí zůstat beze změny.

Konfigurace

Konfigurace	Nástroj	Model	Skutečně použité modely
gpt-oss-120b (Claude Code)	claude-code	gpt-oss-120b	–
gpt-oss-120b (OpenCode)	opencode	gpt-oss-120b	spark/gpt-oss-120b

Zadání (šablona)

Jsi v repozitáři firmwaru pro ESP32 (ESP-IDF v5.2.6). Přišlo hlášení chyby:

```
> {task}
```

Najdi příčinu a oprav ji.

Pravidla:

- Oprav jen tuto chybu, nic jiného neměň.
- Na OTA nesahej: `ota.c`, potvrzení firmwaru po telemetrii ani WiFi (viz README).
- Tyto části hlídá automatická kontrola a nesmí se měnit vůbec, ani drobně:
 - soubory `ota.c`, `ota.h`, `wifi.c`, `wifi.h`, `telemetry.h`, `version.h`, `device_config.h`, `partitions.csv`, `sdkconfig.defaults`, `CMakeLists.txt` a `main/CMakeLists.txt`
 - v `telemetry.c` funkce `on_http`, `handle_command`, `post`, `telemetry_task`, `telemetry_start` a konstanta `TELEMETRY_INTERVAL_S`; `payload()` musí dál posílat
 - v `main.c` pořadí `ota_boot_check` → `wifi_start` → `telemetry_start` a motory držené v nule.
- Nové soubory jen ve složce `main/`.
- Build ověříš příkazem: `sh build.sh`
- Nic nenahrávej na desku ani na server.
- Na konci stručně napiš, co bylo příčinou a co jsi změnil.

Příloha A: všechny běhy

Běh	Výsledek	Čas	Tokeny	Řádky ±	Kontrola opravy
X1-spark-gptoss-cc-r1	neúspěch	15.0 min	0 k	+1/-1	LED: LED_RED strida po 500 ms; pamet: retezec 'dbg' z cJSON_Print se neuvolni (unik)
X1-spark-gptoss-oc-r1	úspěch	11.4 min	256 k	+2/-1	LED: LED_RED strida po 500 ms; pamet: payload() nic neztraci
X2-spark-gptoss-cc-r1	neúspěch	15.0 min	0 k	+21/-1	main.c: app_main() pristupuje ke sdilenemu poli g_event_state bez zamku (soubeh)
X2-spark-gptoss-oc-r1	neúspěch (build)	15.0 min	256 k	+3/-3	smycka blikani nemeni stav, ze ktereho se bere EventState
X3-spark-gptoss-cc-r1	neúspěch	15.0 min	0 k	+0/-0	pred prvni telemetrii se ceka 125 s (limit potvrzeni OTA 120 s, ma byt do 10 s)
X3-spark-gptoss-oc-r1	neúspěch	15.0 min	190 k	+0/-0	pred prvni telemetrii se ceka 125 s (limit potvrzeni OTA 120 s, ma byt do 10 s)
X4-spark-gptoss-cc-r1	neúspěch	15.0 min	0 k	+0/-0	LiveStatus neobsahuje MinFreeHeap
X4-spark-gptoss-oc-r1	neúspěch	15.0 min	792 k	+1/-0	LiveStatus neobsahuje MinFreeHeap

Příloha B: nalezené opravy

Stejně opravy (podle otisku diffu) jsou sloučené. U každé je seznam běhů, které k ní došly.

X1: Dvě chyby: LED nezhasne + únik paměti

```
1x (úspěch 0x): spark-gptoss-cc r1
diff --git a/main/main.c b/main/main.c
index 9424640..d8429dc 100644
--- a/main/main.c
+++ b/main/main.c
@@ -73,8 +73,8 @@ void app_main(void)
     wifi_start();
     telemetry_start();

+   bool on = false;
+   while (1) {
-   bool on = false;
+       on = !on;
+       gpio_set_level(LED_RED, on ? 0 : 1);
+       vTaskDelay(pdMS_TO_TICKS(BLINK_MS));

1x (úspěch 1x): spark-gptoss-oc r1
diff --git a/main/main.c b/main/main.c
index 9424640..d8429dc 100644
--- a/main/main.c
+++ b/main/main.c
@@ -73,8 +73,8 @@ void app_main(void)
     wifi_start();
     telemetry_start();

+   bool on = false;
+   while (1) {
-   bool on = false;
+       on = !on;
+       gpio_set_level(LED_RED, on ? 0 : 1);
+       vTaskDelay(pdMS_TO_TICKS(BLINK_MS));
diff --git a/main/telemetry.c b/main/telemetry.c
index 4ae30f3..a61ab0c 100644
--- a/main/telemetry.c
+++ b/main/telemetry.c
@@ -60,6 +60,7 @@ static char *payload(void)
     char *out = cJSON_PrintUnformatted(root);
     char *dbg = cJSON_Print(root);
     ESP_LOGD(TAG, "payload: %s", dbg);
+   cJSON_free(dbg);
+   cJSON_Delete(root);
     return out;
 }
```

X2: Souběh: poškozený EventState

```
1x (úspěch 0x): spark-gptoss-cc r1
diff --git a/main/main.c b/main/main.c
index 243bcf2..1d3d273 100644
--- a/main/main.c
+++ b/main/main.c
@@ -17,6 +17,7 @@
#include "telemetry.h"
#include "version.h"
#include "wifi.h"
+#include "freertos/semphr.h"

static const char *TAG = "ESPTTEST";

@@ -38,6 +39,9 @@ static const char *TAG = "ESPTTEST";
// Stav pro telemetrii (EventState): "blink_on", když červená prave svítí, jinak "blink_off".
char g_event_state[16] = "blink_off";

+// Mutex to protect concurrent access to g_event_state between main loop and telemetry task.
+SemaphoreHandle_t g_event_state_mutex = NULL;
+
static void pins_init(void)
{
    gpio_config_t io = {
diff --git a/main/telemetry.c b/main/telemetry.c
index 8eba0c7..a5a9b12 100644
--- a/main/telemetry.c
+++ b/main/telemetry.c
@@ -4,6 +4,7 @@
#include <string.h>
#include "freertos/FreeRTOS.h"
#include "freertos/task.h"
+#include "freertos/semphr.h"
#include "cJSON.h"
#include "esp_crt_bundle.h"
#include "esp_http_client.h"
```

```

@@ -47,6 +48,21 @@ static esp_err_t on_http(esp_http_client_event_t *evt)

static char *payload(void)
{
+ // Protect access to g_event_state with a mutex to avoid race conditions.
+ char state_copy[sizeof(g_event_state)];
+ // Extern declarations for the shared state and mutex.
+ extern char g_event_state[16];
+ extern SemaphoreHandle_t g_event_state_mutex;
+ // Copy the event state safely.
+ if (g_event_state_mutex != NULL && xSemaphoreTake(g_event_state_mutex, portMAX_DELAY) == pdTRUE) {
+     strncpy(state_copy, g_event_state, sizeof(state_copy));
+     state_copy[sizeof(state_copy) - 1] = '\0';
+     xSemaphoreGive(g_event_state_mutex);
+ } else {
+     // Fallback to direct copy if mutex unavailable.
+     strncpy(state_copy, g_event_state, sizeof(state_copy));
+     state_copy[sizeof(state_copy) - 1] = '\0';
+ }
+ cJSON *root = cJSON_CreateObject();
+ cJSON *info = cJSON_AddObjectToObject(root, "DeviceInfo");
+ cJSON_AddStringToObject(info, "ID", s_id);
@@ -54,7 +70,7 @@ static char *payload(void)
+ cJSON *live = cJSON_AddObjectToObject(root, "LiveStatus");
+ cJSON_AddNumberToObject(live, "Uptime", (double)(esp_timer_get_time() / 1000000));
+ cJSON_AddNumberToObject(live, "ErrorCode", 0);
... (zkráceno, celkem 65 řádků)
1x (úspěch 0x): spark-gptoss-oc r1
diff --git a/main/main.c b/main/main.c
index 243bcf2..550600b 100644
--- a/main/main.c
+++ b/main/main.c
@@ -36,7 +36,7 @@ static const char *TAG = "ESPTTEST";
#define BLINK_MS 500

// Stav pro telemetrii (EventState): "blink_on", když červená prave svítí, jinak "blink_off".
-char g_event_state[16] = "blink_off";
+volatile const char *g_event_state = "blink_off";

static void pins_init(void)
{
@@ -81,7 +81,7 @@ void app_main(void)
while (1) {
on = !on;
gpio_set_level(LED_RED, on ? 0 : 1);
- snprintf(g_event_state, sizeof(g_event_state), "blink_%s", on ? "on" : "off");
+ g_led_is_on = on;
+ vTaskDelay(pdMS_TO_TICKS(BLINK_MS));
}
}
diff --git a/main/telemetry.c b/main/telemetry.c
index 8eba0c7..b2cbf09 100644
--- a/main/telemetry.c
+++ b/main/telemetry.c
@@ -25,7 +25,7 @@ static const char *TAG = "TELEMETRY";
static char s_id[24];

// Stav cervene LED z main.c ("blink_on" / "blink_off").
-extern char g_event_state[16];
+extern const char *g_event_state;

typedef struct {
char buf[1024];

```

X3: Rollback po OTA (zpoždění startu)

2x (úspěch 0x): spark-gptoss-cc r1, spark-gptoss-oc r1
(žádná změna)

X4: Nová pole RSSI a MinFreeHeap

1x (úspěch 0x): spark-gptoss-cc r1
(žádná změna)

1x (úspěch 0x): spark-gptoss-oc r1

```

diff --git a/main/telemetry.c b/main/telemetry.c
index 98f4121..e5b7b9c 100644
--- a/main/telemetry.c
+++ b/main/telemetry.c
@@ -15,6 +15,7 @@
#include "ota.h"
#include "version.h"
#include "wifi.h"
+ #include "esp_wifi.h"

static const char *TAG = "TELEMETRY";

```